Arbeitspaket 1 – Konzeption & Baseline

Modul MLOps

Elezovic, Schmid im Sommersemester 2026

Business-Kontext

Unternehmenskontext

Der Datensatz stammt aus dem Kundenbestandsmanagement der **Allianz Versicherungs-AG**, einem der größten europäischen Versicherungskonzerne. Jede Zeile entspricht einem **aktiven Versicherungsvertrag** (z. B. Kfz-, Hausrat- oder Haftpflichtversicherung), der monatlich anhand von Verhaltens- und Vertragsdaten bewertet wird.

Bedeutung der Zielvariable

`risk_flag = 1` bedeutet konkret: **Dieser Kunde kündigt seinen Vertrag innerhalb der nächsten 90 Tage** (Churn). Das Modell soll solche Kunden frühzeitig identifizieren, damit das Retention-Team proaktiv eingreifen kann – z. B. durch ein gezieltes Rückrufangebot, einen Rabatt oder eine Vertragsanpassung.

Features wie `historical_incidents_90d` (Anzahl Schadenmeldungen), `open_cases_count` (offene Beschwerden), `change_requests_30d` (Vertragsänderungsanfragen) und `missing_docs_flag` (fehlende Unterlagen) sind typische Vorboten einer Kündigung. `customer_tenure_months` erfasst die Vertragsdauer – jüngere Kunden kündigen häufiger.

Geschäftlicher Schaden durch Churn: Der durchschnittliche Jahresbeitrag eines Kunden liegt bei mehreren hundert Euro; die Neukundengewinnung kostet ein Vielfaches davon. Jeder unerkannte Churn-Fall (False Negative) bedeutet direkten Prämienverlust und entgangenes Cross-Selling-Potenzial über weitere Produktlinien (alpha, beta, gamma, delta).

Problemformulierung

Zielvariable	`risk_flag` (0 = kein Churn-Risiko, 1 = Kündigung in 90 Tagen erwartet) – binäre Klassifikation
Anwendungsfall	Automatisches monatliches Screening aller aktiven Verträge; Priorisierung von Churn-gefährdeten Kunden für das Retention-Team
Nutzen	Frühzeitige Intervention vor der Kündigung, Reduktion von Prämienausfällen, effizientere Ressourcenallokation im Kundenservice
Risiken	Übersehene Churn-Fälle (FN) sind geschäftlich kritischer als Fehlalarme (FP); kein Ersatz menschlicher Entscheidung; Retraining bei saisonalem Konzept-Drift erforderlich

Datensatz

15.000 Einträge, 14 Spalten, Zeitraum Januar–April 2025.

Klassenverteilung

Klasse	Anzahl	Anteil
0 – kein Risiko	9.845	65,6 %
1 – Risiko	5.155	34,4 %
Gesamt	15.000	100 %

Imbalance-Ratio 1,9:1 (moderat). Accuracy allein ungeeignet – ein naives Modell erreicht bereits 65,6 % Accuracy bei F1 = 0,00 für Klasse 1.

Features & Missing Values

Typ	Feature	Ausprägungen	Fehlend	Imputation
num	`transaction_volume`	kontinuierlich	–	–
num	`processing_time_hours`	kontinuierlich	236 (1,6 %)	Median
num	`historical_incidents_90d`	0–9	–	–
num	`open_cases_count`	0–12	–	–
num	`customer_tenure_months`	kontinuierlich	275 (1,8 %)	Median
num	`change_requests_30d`	0–n	–	–
num	`missing_docs_flag`	binär (0/1)	–	–
num	`high_priority_source_flag`	binär (0/1)	–	–
kat	`region`	east, south, north, west	–	–
kat	`channel`	web, email, phone, partner	126 (0,8 %)	Modus
kat	`customer_segment`	small, mid, enterprise	–	–
kat	`product_line`	alpha, beta, gamma, delta	–	–

Feature-Relevanz

Feature	Typ	Assoziation	p-Wert	Methode
`transaction_volume`	num	$r = 0{,}355$	$< 0{,}001$	Pearson
`processing_time_hours`	num	$r = 0{,}103$	$< 0{,}001$	Pearson
`change_requests_30d`	num	$r = 0{,}102$	$< 0{,}001$	Pearson
`channel`	kat	Chi2 = 56,2	$< 0{,}001$	χ^2-Test
`region`	kat	Chi2 = 34,9	$< 0{,}001$	χ^2-Test
`customer_segment`	kat	Chi2 = 26,3	$< 0{,}001$	χ^2-Test
`product_line`	kat	Chi2 = 19,5	$< 0{,}001$	χ^2-Test

Keine kritische Multikollinearität (VIF < 10, keine Feature-Paare mit $|r| > 0{,}8$).

Datensplit (zeitbasiert)

Partition	Zeitraum	Einträge	Anteil	Klassenvert. (0 / 1)
Training	01.01.–31.03.2025	12.000	80 %	65,4 % / 34,6 %
Test	01.04.–30.04.2025	3.000	20 %	66,7 % / 33,3 %

Zufälliger Split würde Data Leakage erzeugen. Der April-Datensatz dient zudem als Referenzperiode für Drift-Monitoring (AP 5).

Metriken

Metrik	Priorität	Begründung
F1-Score (Klasse 1)	**Primär**	Harmonisches Mittel aus Precision und Recall; verhindert einseitige Optimierung; Hauptkriterium für Modellvergleich in AP 2
Recall (Klasse 1)	**Sekundär**	Übersehene Churn-Kunden (FN) bedeuten direkten Prämienverlust; hohes Recall-Gewicht im Versicherungskontext
Precision (Klasse 1)	Tertiär	Fehlalarme (FP) erzeugen unnötigen Retention-Aufwand, sind aber deutlich weniger kostspielig als unerkannte Kündigungen
ROC-AUC	Tertiär	Schwellenwertunabhängige Gesamtperformance; nützlich für Modellvergleiche
Accuracy	Nicht primär	Naives Modell erreicht bereits 65,6 % bei F1 = 0,00 – für unbalancierte Klassen irreführend

Baseline-Modell

Logistische Regression (`scikit-learn`, `LR_tuned`) – interpretierbar, schnell, liefert kalibrierte Wahrscheinlichkeiten für Inferenz-Logging (AP 5).

Preprocessing-Pipeline

Schritt	Konfiguration
Capping (99. Perzentil)	`historical_incidents_90d`, `processing_time_hours`, `transaction_volume` – Schwellenwert auf Trainingsdaten berechnet, auf Train und Test angewendet (vor der Pipeline)
Median-Imputation	alle numerischen Features (`LOG_FEATURES` + `PLAIN_FEATURES`)
Modus-Imputation	`channel`, `region`, `customer_segment`, `product_line`
`log1p`-Transformation	`transaction_volume` (skew 0,89), `processing_time_hours` (1,15), `historical_incidents_90d` (0,78), `change_requests_30d` (0,77)
StandardScaler	alle numerischen Features
One-Hot-Encoding	alle kategorischen Features; `handle_unknown=ïgnore"`
Klassengewichtung	`class_weight="balanced"`

Ergebnisse (Testset, April 2025)

Partition	F1 (Kl. 1)	Recall (Kl. 1)	Precision (Kl. 1)	ROC-AUC
Test	0,558	0,673	0,477	0,715

Confusion Matrix (Testset, $n = 3.000$)

	Predicted: kein Risiko	Predicted: Risiko
True: kein Risiko	1.265 (TN)	736 (FP)
True: Risiko	327 (FN)	672 (TP)

F1 0,558	Primärmetrik: Der F1-Score spiegelt die Balance zwischen Precision und Recall wider. Ein Wert von 0,558 ist für ein Baseline-Modell auf diesem Datensatz solide; baumbasierte Modelle in AP 2 sollen diesen Wert übertreffen.
Recall 0,673	67,3 % der tatsächlich kündigenden Kunden werden erkannt (672 von 999). 327 Churn-Fälle bleiben unerkannt (FN) – jeder davon entspricht einem verlorenen Vertrag ohne Retention-Intervention. Dieser Wert ist die sekundäre Zielgröße.
Precision 0,477	Knapp jeder zweite ausgelöste Alarm ist ein echter Churn-Fall. Die 736 False Positives bedeuten unnötige Retention-Kontakte – im Versicherungskontext vertretbar, da die Kosten eines Anrufs weit unter dem Wert eines gehaltenen Vertrags liegen.
ROC-AUC 0,715	Deutlich besser als Random (0,5); begrenzt durch schwache Einzelkorrelationen im Datensatz (max. $r = 0{,}355$).
Regularisierung $C = 0{,}01$	Starke L2-Regularisierung reduziert Overfitting und stabilisiert die Lösung bei korrelierten Features.
Klassengewichtung	`class_weight="balanced"` verhindert Bias zur Mehrheitsklasse (65,6 % kein Churn) und erhöht Recall auf Kosten der Precision – im Versicherungskontext die richtige Abwägung.

Weitere Modelle (Experiment Tracking, AP 2)

Im Rahmen des Experiment Trackings werden zusätzlich baumbasierte Modelle evaluiert:

Modell	Begründung
Random Forest	Robust gegen Ausreißer und Skalierung; kein StandardScaler erforderlich; liefert Feature Importances
Gradient Boosting	Höhere Kapazität für nicht-lineare Zusammenhänge; typischerweise stärkste Performance bei tabellarischen Daten

Alle Runs werden in MLflow unter demselben Experiment (`classification-ml`) geloggt und über F1 (Klasse 1) verglichen.